

Laboratorio di Intelligenza Artificiale

Appunti di corso – A.A. 2025/2026

Prof. Giacomo Fiumara – Università di Messina

Testi di riferimento:

Russell & Norvig, *Artificial Intelligence: A Modern Approach*

A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow*

Appunti basati sul materiale di Aurora Fabio

Capitolo 1

Introduzione all'IA

Lezione 1 – 24/02/2026 – Russell & Norvig, Cap. 1 (1.1–1.5)

1.1 Che cos'è l'Intelligenza Artificiale?


Definizione

L'**Intelligenza Artificiale** è la disciplina che studia la costruzione di *entità intelligenti*: macchine in grado di **calcolare come agire efficacemente e in modo sicuro** in un'ampia varietà di situazioni nuove.

L'IA è uno dei campi più interessanti e in rapida crescita di oggi, con un fatturato annuale superiore a **mille miliardi di dollari**. Abbraccia una vasta varietà di sottocampi: apprendimento, ragionamento, percezione, giochi, dimostrazione di teoremi, guida autonoma, diagnostica medica e molto altro.

Storicamente, la ricerca sull'IA ha seguito quattro grandi approcci, incrociando due dimensioni:

- **Umano vs. Razionale**: la macchina deve imitare le prestazioni umane o perseguire una razionalità astratta (fare la “cosa giusta”)?
- **Pensiero vs. Comportamento**: ci si concentra sui processi mentali interni o sul comportamento osservabile?



1.1.1 Approccio 1 – Acting Humanly: il Test di Turing

Alan Turing (1950) propose un esperimento mentale: un computer supera il test se un interrogatore umano, dopo aver posto domande scritte, non riesce a distinguere le risposte di una macchina da quelle di una persona.

Per superare il test una macchina deve possedere:

1. **Natural Language Processing (NLP)**: comunicare con successo in linguaggio umano.
2. **Knowledge Representation**: memorizzare ciò che percepisce o apprende.
3. **Automated Reasoning**: usare le informazioni salvate per rispondere e trarre conclusioni.
4. **Machine Learning**: adattarsi a nuove circostanze e rilevare pattern.

Il *Total Turing Test* aggiunge un segnale video, richiedendo anche **Computer Vision** e **Robotica**. Nonostante la sua eleganza, i ricercatori preferiscono studiare i principi sottostanti dell'intelligenza piuttosto che ottimizzare il superamento del test.

L'argomento della stanza cinese (Searle, 1980)

Superare il test non implica *capire*: un programma potrebbe manipolare simboli senza comprensione, come un uomo chiuso in una stanza che traduce ideogrammi cinesi seguendo manuali senza conoscere la lingua.

1.1.2 Approccio 2 – Thinking Humanly: la modellazione cognitiva

Per dire che un programma “pensa come un umano” bisogna prima capire come gli umani pensano. Tre metodi:

- **Introspezione**: osservare i propri pensieri mentre accadono.
- **Esperimenti psicologici**: osservare persone che svolgono compiti e confrontare il loro comportamento con programmi per computer.
- **Brain imaging**: osservare il cervello in azione (fMRI, EEG, MEG).

La **scienza cognitiva** combina modelli computazionali dell'IA con tecniche sperimentali della psicologia per costruire teorie precise e verificabili della mente umana. L'obiettivo è capire gli schemi mentali umani per riprodurli. Si basa su introspezione, esperimenti psicologici e brain imaging.

1.1.3 Approccio 3 – Thinking Rationally: le leggi del pensiero

Aristotele fu tra i primi a codificare il “pensiero corretto” tramite i **sillogismi** (“Socrate è un uomo; tutti gli uomini sono mortali; quindi Socrate è mortale”). Nel XIX secolo i logici svilupparono notazioni precise per ragionare su oggetti e relazioni.

- **Logica formale** (Boole 1847, Frege 1879): fondamento del ragionamento deduttivo in IA.
- **Teoria della probabilità** (Bayes, Laplace): estende la logica al ragionamento in condizioni di incertezza. (C'è il 30% di probabilità di pioggia)

Due ostacoli principali: è difficile tradurre la conoscenza informale in notazione formale e molti problemi, anche con pochi fatti, risultano intrattabili.

1.1.4 Approccio 4 – Acting Rationally: l'agente razionale

Agente razionale

Un **agente** è un'entità che agisce. Gli agenti software operano *autonomamente, percepiscono l'ambiente, persistono nel tempo, si adattano al cambiamento e perseguono obiettivi*.

Un **agente razionale** agisce in modo da ottenere il *miglior risultato atteso*, anche in condizioni di incertezza.

Questo approccio è **più generale** del “pensare razionalmente”: l'inferenza corretta è solo uno dei meccanismi per essere razionali. È anche più adatto allo sviluppo scientifico, perché la razionalità è definita matematicamente in modo preciso e universale. È l'approccio prevalente nell'IA moderna, nella teoria del controllo, nella ricerca operativa, nella statistica e nell'economia.

Il Modello Standard e i suoi limiti

Il “Modello Standard” dell'IA assume che il progettista conosca esattamente la funzione obiettivo. È pericoloso: se l'obiettivo è mal specificato si ottengono comportamenti indesiderati. Russell propone un modello alternativo: la macchina è incerta sull'obiettivo umano e impara a inferirlo.

1.2 Fondamenti dell'Intelligenza Artificiale

1.2.1 Filosofia

- **Dualismo** (Cartesio): la mente è separata dalla materia fisica ed è esente dalle leggi fisiche.
- **Empirismo** (Locke, Hume, Bacon): la conoscenza emerge dall'esperienza sensoriale. “Nulla è nell'intelletto che non sia stato prima nei sensi”.
- **Principio di induzione** (Hume): le regole generali si acquisiscono tramite l'esposizione ripetuta ad associazioni tra elementi.
- **Positivismo logico** (Circolo di Vienna): tutta la conoscenza è caratterizzata da teorie logiche collegate a osservazioni sensoriali.
- **Conoscenza e azione**: Aristotele propose che le azioni siano giustificate da connessioni logiche tra obiettivi e conoscenza degli esiti.

1.2.2 Matematica

- **Logica formale**: Boole (1847), logica proposizionale; Frege (1879), logica del primo ordine con oggetti e relazioni.
- **Probabilità**: Cardano, Pascal, Bayes, Laplace. La **regola di Bayes** è fondamentale per il ragionamento sotto incertezza in IA.
- **Calcolabilità**: Gödel (1931), Turing (1936), Church. La *Church–Turing thesis* identifica la calcolabilità con le macchine di Turing. Alcune funzioni non sono calcolabili.
- **Trattabilità**: la distinzione tra crescita polinomiale ed esponenziale è fondamentale. Molti problemi di IA sono NP-completi e richiedono un uso attento delle risorse computazionali.

1.2.3 Economia

- **Teoria delle decisioni:** combina probabilità e utilità per un framework formale per decisioni sotto incertezza (von Neumann & Morgenstern, 1944).
- **Teoria dei giochi:** analizza situazioni in cui le decisioni di più agenti si influenzano reciprocamente. Gli agenti razionali possono adottare strategie randomizzate.
- **Processi decisionali di Markov** (Bellman, 1957): formalizzano i problemi decisionali sequenziali, base del Reinforcement Learning.
- **Satisficing** (Simon): gli umani spesso prendono decisioni “abbastanza buone” piuttosto che ottimali – descrive meglio il comportamento reale.

1.2.4 Neuroscienze

Il **neurone** è l'unità base del sistema nervoso: corpo cellulare (soma), dendriti (input) e assone (output). Un neurone si connette con 10–100 000 altri neuroni alle sinapsi tramite reazioni elettrochimiche. Il cervello umano ha $\sim 10^{11}$ neuroni e $\sim 10^{14}$ sinapsi.

Cervello vs. Computer

Il cervello è 10^6 volte più lento nel ciclo di clock rispetto a un computer moderno, ma compensa con enorme capacità di storage e connettività.

1.2.5 Psicologia

- **Comportamentismo** (Watson, Skinner): rifiuta l'introspezione; studia solo le relazioni oggettive stimolo–risposta.
- **Psicologia cognitiva** (James, Craik): vede il cervello come un dispositivo di elaborazione dell'informazione. Le percezioni e le azioni sono mediate da rappresentazioni interne.
- **Modello di Craik (1943):** (1) stimolo $\rightarrow$ rappresentazione interna; (2) manipolazione cognitiva; (3) retraduzione in azione.
- **Scienza cognitiva** (1956): combina modelli computazionali e psicologia sperimentale; Miller, Chomsky, Newell & Simon dimostrarono che i computer possono modellare memoria, linguaggio e ragionamento.

1.2.6 Ingegneria informatica

- I moderni calcolatori nascono durante la Seconda Guerra Mondiale: **Colossus** (UK, 1943), **Z-3** (Zuse, 1941), **ENIAC** (USA, 1945).
- **Legge di Moore:** la potenza computazionale raddoppia ogni 18 mesi, grazie a questa legge, le prestazioni dei PC sono passate dai megaFLOP (milioni di operazioni in virgola mobile al secondo) agli attuali exaFLOP (miliardi di miliardi di operazioni al secondo).
- **Hardware specializzato:** GPU (NVIDIA), TPU (Google), WSE per l'addestramento di modelli di ML. Dal 2012 al 2018, la potenza per il training è cresciuta di $300.000\times$.
- **Quantum computing:** Il bit classico vale 0 o 1. Il Qubit (bit quantistico), grazie al principio di sovrapposizione, può assumere infiniti valori compresi tra 0 e 1 contemporaneamente.

1.2.7 Teoria del controllo e cibernetica

- Sistemi di feedback autoregolanti precedono i computer: orologio ad acqua (Ktesibios), regolatore del motore a vapore (Watt), termostato (Drebbel).
- **Teoria del controllo** (Maxwell, Wiener): framework matematico per sistemi che minimizzano l'errore tra stato corrente e stato obiettivo.
- **Cibernetica** (Wiener, 1948): studia il comportamento finalistico che emerge da meccanismi regolatori in macchine e organismi.
- **Controllo ottimo stocastico**: progetta sistemi che massimizzano una funzione obiettivo nel tempo – parallelo diretto con l'obiettivo dell'IA.

1.2.8 Linguistica

- **Comportamentismo linguistico** (Skinner, 1957): il linguaggio si apprende per associazioni stimolo-risposta.
- **Strutture sintattiche** (Chomsky, 1957): il linguaggio mostra creatività – i bambini comprendono e producono frasi mai sentite prima. La sintassi formale di Chomsky spiegò questo fenomeno e poteva essere programmata.
- Linguistica moderna e IA nacquero quasi contemporaneamente, dando origine alla **linguistica computazionale** e al **Natural Language Processing**.
- Insight chiave: comprendere il linguaggio richiede conoscenza del dominio e del contesto, non solo regole sintattiche – legato alla **rappresentazione della conoscenza**.

1.3 Storia dell'Intelligenza Artificiale

1.3.1 Le origini (1943–1956)

- **McCulloch & Pitts (1943)**: primo modello formale del neurone artificiale; qualsiasi funzione calcolabile può essere computata da reti di neuroni.
- **Hebb (1949)**: regola di apprendimento hebbiano – “neurons that fire together wire together”.
- **Turing (1950)**: propone il Turing Test, introduce machine learning e algoritmi genetici.
- **Conferenza di Dartmouth (1956)**: McCarthy, Minsky, Shannon e Rochester organizzano il workshop – **nascita ufficiale dell'IA** come campo.

1.3.2 Entusiasmo e aspettative (1952–1969)

- **Logic Theorist** (Newell & Simon, 1956): dimostra teoremi di logica formale; Russell rimase deliziato quando il programma trovò una dimostrazione più breve della sua.
- **General Problem Solver** (anni '60): imita i protocolli umani di problem solving – primo approccio “Thinking Humanly”.
- **LISP** (McCarthy, 1958): linguaggio dominante dell'IA per 30 anni.
- **Microworlds** (anni '60): domini limitati (es. il blocchi-mondo di SHRDLU) dove il problem solving sembrava richiedere intelligenza.

1.3.3 Una dose di realtà e i primi inverni (1966–1986)

- I sistemi fallivano su problemi più grandi per **esplosione combinatoria**: scalare a istanze reali si rivelò impraticabile.
- **Minsky & Papert (1969)**: dimostrano i limiti del perceptrone (non può risolvere XOR) → blocca la ricerca sulle reti neurali per anni.
- **Rapporto Lighthill (1973)**: critica i fallimenti dell'IA → taglio dei finanziamenti britannici.
- **Sistemi esperti** (DENDRAL 1969, MYCIN anni '70, R1/XCON 1982): primo successo commerciale – conoscenza di dominio specifica invece di metodi deboli generali. Ma fragili di fronte a incertezza e casi nuovi → secondo inverno (fine anni '80).

1.3.4 Rinascita e Deep Learning (1986–oggi)

- **Backpropagation** (Rumelhart, Hinton, Williams 1986): ri-scoperta e applicazione a molti problemi di apprendimento.
- **Reti bayesiane** (Pearl, 1988): framework rigoroso per il ragionamento probabilistico.
- **Big Data** (2001–oggi): raddoppiare i dati supera qualsiasi miglioramento algoritmico (Banko & Brill, 2001).
- **ImageNet 2012**: AlexNet di Hinton segna l'inizio del dominio del **Deep Learning**.
- Pietre miliari recenti: **AlphaGo** (2016), **Transformer** (2017), **GPT-3** e **AlphaFold** (2020), **ChatGPT** (2022), multimodalità e agenti autonomi (2024+).

1.4 Stato dell'arte

Le pubblicazioni di IA sono aumentate di 20 volte tra il 2010 e il 2019.

Applicazioni reali oggi

- **Sanità**: diagnosi di malattie, scoperta di farmaci.
 - **Guida autonoma**: veicoli STANLEY (DARPA 2005), sistemi Waymo, Tesla.
 - **NLP**: traduzione automatica, assistenti vocali, LLM (GPT-4, Gemini, Claude).
 - **Scienza**: AlphaFold (DeepMind, 2020) ha risolto la predizione 3D delle proteine.
 - **Giochi**: Deep Blue (scacchi, 1997), AlphaGo (Go, 2016), AlphaStar (2019).
 - **Spam filtering**: algoritmi di ML classificano un miliardo di messaggi al giorno.
-
- **Interpretabilità (xAI)**: i sistemi DL sono spesso *black box*. LIME, SHAP, Grad-CAM tentano di renderli trasparenti.
 - **Robustezza**: vulnerabilità a *adversarial examples* e input fuori distribuzione.
 - **Generalizzazione**: trasferire la conoscenza da un dominio all'altro rimane difficile.
 - **Fairness e bias**: i sistemi di IA possono amplificare i pregiudizi nei dati di addestramento.
 - **Consumo energetico**: il training di modelli grandi consuma enormi quantità di energia (GPT-3: ~1287 MWh).

1.5 Rischi e benefici dell'IA

1.5.1 Il Problema dell'Allineamento dei Valori

Modello Standard

Il **Modello Standard** dell'IA prevede la progettazione di sistemi che raggiungono un obiettivo specificato dall'utente. Assume che possiamo specificare completamente l'obiettivo. In realtà, in problemi aperti del mondo reale, questo è spesso impossibile.

Value Alignment Problem

Il **problema dell'allineamento dei valori** è la sfida di garantire che gli obiettivi programmati in una macchina siano *allineati con i valori umani*. Un sistema sufficientemente capace che persegue un obiettivo fisso potrebbe trovare modi inattesi per raggiungerlo.

Verso un'IA provabilmente benefica (Russell, *Human Compatible*, 2019)

Poiché non possiamo trasferire tutti gli obiettivi a una macchina, serve un approccio in cui la macchina persegue i nostri obiettivi *rimanendo incerta su quali siano davvero*. Questo la incentiva a: agire con **cautela**, chiedere **permesso** prima di azioni importanti, **apprendere** le preferenze umane, e **delegare il controllo** all'uomo in caso di incertezza.

1.5.2 Rischi e benefici

Principali benefici

- **Sanità:** diagnosi, scoperta di farmaci, medicina personalizzata.
- **Scienza:** accelera la ricerca in fisica, biologia, chimica.
- **Economia:** automazione, ottimizzazione, supporto decisionale.
- **Accessibilità:** strumenti per persone con disabilità, risposta alle emergenze.

Principali rischi

- **Disoccupazione tecnologica:** l'automazione può eliminare posti di lavoro più rapidamente di quanto ne crei.
- **Bias e discriminazione:** i sistemi amplificano i pregiudizi nei dati.
- **Disinformazione:** deepfake, testo sintetico e media manipolati diffondono informazioni false su scala.
- **Privacy e sorveglianza:** la raccolta massiva di dati abilita una sorveglianza senza precedenti.
- **Concentrazione del potere:** i benefici dell'IA rischiano di concentrarsi in poche grandi aziende o nazioni.
- **Armi autonome:** sistemi militari basati sull'IA sollevano gravi preoccupazioni etiche ed esistenziali.

- **AI Act UE (2024):** prima regolamentazione orizzontale sull'IA; impone requisiti di trasparenza, robustezza e supervisione umana in base al livello di rischio.
- **Collaborazione interdisciplinare:** informatici, etici, filosofi, scienziati sociali ed esperti di dominio devono lavorare insieme.
- **Ricerca fondamentale:** progressi su interpretabilità, robustezza, fairness e allineamento rimangono essenziali.