



Confronto di tecniche di embeddings in ambienti di Graph Data Science distribuiti: un caso di studio in ambito biomedico

Candidato

Sandi Russo


Relatore

Prof. Antonio Celesti

Il modello Property Graph

Un database a grafo archivia e rappresenta l'informazione attraverso nodi e relazioni. La sua massima espressione è **Neo4j**.

- **Nodo:** rappresenta un'entità nel grafo
- **Relazione:** connette i nodi con tipo e direzione
- **Proprietà:** coppie chiave-valore su nodi e relazioni
- **Label:** classificano semanticamente i nodi



Graph Data Science

La GDS combina algoritmi su grafi e tecniche di **Machine Learning** per estrarre conoscenza predittiva dalla struttura topologica di reti complesse, superando i limiti dei database relazionali.

Queries


Esplorare il grafo per trovare schemi e pattern noti.

Machine Learning

Fare previsioni su connessioni non ancora documentate.

Visualization

Visualizzare e analizzare i risultati degli algoritmi.



Il problema: drug repurposing

Identificare nuove applicazioni terapeutiche per farmaci già esistenti è più rapido ed economico della ricerca tradizionale, ma richiede l'analisi di reti biologiche di **scala massiva**.

Lacuna algoritmica

La maggior parte dei lavori valuta i modelli su dataset omogenei o di dimensioni contenute. Manca un confronto strutturato su KG biomedici reali di scala massiva.

Lacuna infrastrutturale

La letteratura assume il grafo già in memoria, ignorando la fase critica di estrazione da un Graph DBMS distribuito verso il framework di apprendimento.

Obiettivo: una valutazione **end-to-end** che colleghi infrastruttura distribuita e qualità predittiva degli embedding.

Il dataset: PharMeBiNet V3

Un knowledge graph biomedico open-source che integra oltre quaranta sorgenti farmacologiche, genomiche e cliniche in un'unica struttura a grafo eterogeneo .

8M

nodi su 80 label distinte

53M

relazioni di 410 tipi

123.361

archi Chemical→Disease

Scelto per scala, eterogeneità strutturale e rilevanza applicativa nel contesto del drug repurposing.


I tre paradigmi a confronto

La scelta degli algoritmi esplora tre filosofie architetturali distinte, permettendo di isolare l'impatto di ciascuna sulla qualità degli **embedding** prodotti.

	GraphSAGE	HashGNN	TransE
Paradigma	Induttivo	Induttivo	Trasduttivo
Spazio embedding	Omogeneo	Eterogeneo	Geometrico
Aggregazione vicinato	Sì	Sì	No
Generalizza a nodi nuovi	Sì	Sì	No
Gestione eterogeneità	No	Sì	No

GraphSAGE

Apprende una **funzione di aggregazione** generalizzabile invece di un vettore fisso per nodo, generalizzando a entità non osservate durante il training.



Campionamento

Sottoinsieme fisso di vicini:
costo costante
indipendentemente dal
grado del nodo.

Aggregazione

Vicini aggregati e
combinati con lo stato del
nodo tramite
concatenazione lineare.

Limite

Tratta il grafo come
omogeneo: non distingue
tipi di nodo né di relazione.

TransE e HashGNN

Due approcci alternativi che esplorano filosofie architetture opposte rispetto a GraphSAGE.

TransE

Modella le relazioni come **traslazioni geometriche** nello spazio latente.

Data una tripla (h, r, t) , ottimizza gli embedding affinché:

$$\mathbf{h} + \mathbf{r} \approx \mathbf{t}$$

Nessuna aggregazione di vicinato.


Approccio **trasduttivo**: non generalizza a entità nuove ma cattura esplicitamente la semantica delle relazioni.

HashGNN

Progettato nativamente per grafi **eterogenei**. Mantiene spazi di rappresentazione separati per ogni tipo di nodo tramite proiezioni casuali fisse ispirate al *Locality-Sensitive Hashing*. Approccio **induttivo**: evita il collasso semantico che GraphSAGE introduce fondendo tutti i tipi di nodo.

Architettura del cluster Neo4j

Neo4j Enterprise distribuito su **4 macchine virtuali Azure** in topologia primary-secondary, orchestrato tramite Ansible.



Primary


Scritture e consenso distribuito tramite protocollo Raft.

Secondary

Sola lettura: scalano le operazioni di estrazione dati.

Pipeline sperimentale


Dal KG biomedico agli embedding, fino alla valutazione: una pipeline **end-to-end** che collega infrastruttura e apprendimento automatico.



5 run indipendenti · 200 epoche · test split 10% · seed 42

Benchmark infrastrutturale

Tempo di estrazione del sottografo Chemical→Disease da Neo4j verso PyTorch Geometric al variare dei **nodi attivi nel cluster**.



Risultato


I tempi sono sostanzialmente costanti tra le tre configurazioni. Il bottleneck è la **capacità di I/O sequenziale**, non la disponibilità di nodi.

Sweet spot

La configurazione a 2 nodi risulta leggermente più veloce: l'overhead di coordinamento supera il vantaggio con 4 nodi attivi.

Risultati: accuratezza

Tutti e tre i modelli raggiungono un'accuratezza elevata. **GraphSAGE** domina con la deviazione standard più bassa, indicando alta stabilità statistica tra le run.




0.9934
GraphSAGE

0.9923
HashGNN

0.9839
TransE

Risultati: efficienza e trade-off

TransE è il più veloce di un margine significativo. GraphSAGE domina HashGNN in senso di Pareto: più accurato e più veloce contemporaneamente.



145s

TransE, il più veloce

448s

GraphSAGE

624s

HashGNN, il più lento

Verifica delle ipotesi

Le ipotesi iniziali sono state in parte **smentite**, con risultati scientificamente rilevanti in entrambi i casi.

Ipotesi	Attesa	Risultato
Modello più accurato	HashGNN	GraphSAGE
HashGNN supera GraphSAGE	Sì	No
Speedup con 4 nodi	Sì	No
TransE più efficiente	Sì	Sì

Un'ipotesi smentita con metodologia rigorosa ha lo stesso valore scientifico di un'ipotesi confermata.

Contributi e sviluppi futuri

Contributi originali

- Validazione empirica di tre paradigmi di embedding su un KG biomedico reale di scala massiva
- Profilazione end-to-end dell'overhead infrastrutturale da Graph DBMS distribuito a framework ML
- Infrastruttura riproducibile tramite *Infrastructure as Code* con Ansible

Sviluppi futuri

- Estendere il confronto all'intero grafo eterogeneo con tutti i 410 tipi di relazione
- Aumentare il numero di epoche per HashGNN, penalizzato dalla convergenza più lenta
- Valutare l'impatto del cluster su carichi di lettura paralleli
- Integrare embedding nativi della libreria GDS di Neo4j

Conclusioni

La GDS si conferma un paradigma efficace per l'analisi predittiva su KG biomedici di scala massiva, ma la scelta dell'algoritmo non è neutrale: ogni approccio riflette **assunzioni architetturali** con impatti misurabili sulla qualità degli embedding.

GraphSAGE

Migliore accuratezza e convergenza rapida. Vince nonostante l'approccio omogeneo.

TransE

Vincitore dell'efficienza. Tre volte più veloce con un sacrificio minimo in accuratezza.

Infrastruttura

Il beneficio reale del cluster è la fault tolerance, non lo speedup su query sequenziali.



Grazie per l'attenzione

Sandi Russo

Relatore: Prof. Antonio Celesti

Università degli Studi di Messina

A.A. 2025/2026